

機械学習

佐々木翔太

1 分類

1.1 ロジスティック回帰による 2 値分類

1.1.1 目的

ここでは、ロジスティック回帰を構成する各要素の必然性を明らかにする事を目的とする。

1.1.2 2 値分類タスクの問題設定

2 値分類タスク¹とは、入力 $\mathbf{x}$ をその内容に応じて 2 種類に区別する問題である。クラスラベルは、2 値の変数 $k \in \{0, 1\}$ で表現するものとする。2 値分類タスクの目標は、入力 $\mathbf{x}$ から k を推定する事である。

この問題を定式化するため、入力 $\mathbf{x}$ を指定した時 $k = 1$ となる事後確率² $p(k = 1|\mathbf{x})$ を考える³。 $\mathbf{x}$ が与えられた時、事後確率 $p(k = 1|\mathbf{x})$ を計算し、その値が 0.5 を超えれば $k = 1$ 、下回れば $k = 0$ と判断する⁴。

ここでは、入力を I 次元の列ベクトル $\mathbf{x} \in \mathbb{R}^I$ と定義する。例えば画像の 2 値分類タスクであれば、 $\mathbf{x}$ は画像から抽出された単一の特徴ベクトルを意味する。また、セグメンテーションや物体検出などの 2 値分類タスクであっても、最終的には「特定のピクセルやグリッドにおける特徴ベクトルに対する独立した 2 値分類の反復」に帰着する⁵。 よって、入力データの次元に依らず、2 値分類モデルは「列ベクトル $\mathbf{x}$ から事後確率 $p \in (0, 1)$ への写像（全射）⁶」として一般化して議論できる。

$$\begin{aligned} f: \mathbb{R}^I &\rightarrow (0, 1), \quad \mathbf{x} \mapsto p \\ \mathbf{x} &= \begin{pmatrix} x_1 \\ \vdots \\ x_I \end{pmatrix} \in \mathbb{R}^I, \quad p \in (0, 1) \end{aligned} \tag{1}$$

なお、 $p \in (0, 1)$ であり、 $p \in [0, 1]$ ではない。この理由は、ロジスティックシグモイド関数⁷の議論において後述する。

1.1.3 2 値分類モデルが満たすべき条件

前項で定式化した 2 値分類モデルを設計するにあたり、モデルの出力値は少なくとも 2 つの条件を満たす必要がある。

¹以降は「2 値分類」という言葉の使用を避け、「2 値分類タスク」なのか「2 値分類モデル」なのかを明示する。

²C. M. ビショップ：パターン認識と機械学習 上 ベイズ理論による統計的予測，p.16，シュプリンガー・ジャパン株式会社，東京（2008）。

³ p は、入力 $\mathbf{x}$ に対してダイナミックに変化するため、条件付き確率である。ここでは事後確率と呼ぶ。

⁴岡谷貴之：深層学習 改訂第 2 版，p.19，講談社，東京（2024）。

⁵要出典

⁶数学の景色：関数とは何か、写像とは何かを図解～定義と表記法と具体例～，<https://mathlandscape.com/function/#toc8>，（2026 年 4 月 30 日参照）。

⁷「ロジスティック関数」とも呼ばれる。

条件 1：不確実性を表現する「確率」である事

現実の対象が持つ完全な情報を有限次元の特徴ベクトル $\mathbf{x}$ に圧縮して観測する以上、観測されていない潜在変数⁸⁹が存在する。この情報の欠落により、現実にはクラス $k = 0$ に属するデータと $k = 1$ に属するデータが、特徴空間上で全く同じ座標に位置する可能性がある。例えば、ある人物について「身長 170cm」という特徴ベクトル $\mathbf{x}$ が与えられ、その人物の性別を予測するタスクを考えると、正解ラベルは女性にも男性にもなり得る。

同一の入力 $\mathbf{x}$ に対して、正解ラベルが複数存在し得る以上、予測モデルは絶対的な $\{0, 1\}$ の判断ではなく、不確実性を表す値を出力する必要がある。

そして、不確実性について合理的で一貫した推論を行う唯一の枠組みが確率論であるため、不確実性を表現するために確率を使う¹⁰。

条件 2：大部分において「微分可能な連続関数」である事

前項により、モデルの出力値は確率となったが、これだけではモデルの学習は保証されない。ロジスティック回帰モデルのパラメータ最適化に勾配降下法を採用する事を仮定すると、入力 $\mathbf{x}$ から確率 p への写像（モデル）は、定義域の大部分において微分可能な連続関数でなければならない¹¹。たとえ出力値が確率であっても、入力の変化に対して確率が階段状に変化する離散的な関数であった場合、その微分値は至る所で 0 となり、勾配が消失してしまう。よって学習を成立させるためには、モデルは単に確率を出力するだけでなく、入力に対して滑らかに連続変化する微分可能な関数として設計されなければならない。

これまでの説明により、2 値分類モデルの出力は「確率」であり、かつ「微分可能な連続関数」でなければならない事が示された。以降では、これらの条件を満たす具体的なモデルを設計する。

1.1.4 2 値分類モデル（ロジスティック回帰モデル）の具体的設計

ニューラルネットワークの設計

前項までの要件を満たす事後確率 $p(k = 1|\mathbf{x})$ をモデル化するために、最も基本的なニューラルネットワーク構造であるロジスティック回帰モデルを採用する。本モデルのネットワーク構造は、以下の 2 つの理由から「入力層を出力層の単一ユニットへ直接結合する」最も単純な構成に一意に定まる。

第 1 に、ネットワークの「深さ（隠れ層）」の排除である。1.1.2 節において、入力 $\mathbf{x}$ は前段の特徴抽出器（CNN 等）によって、既に表現力を持つ特徴ベクトルとして抽出されていることを前提としている。したがって、分類器の内部に隠れ層を追加してさらなる表現力を持つ必要はなく、むしろ分類器としての純粋な役割を逸脱するため行うべきではない。

第 2 に、ネットワークの「出力層の幅（ユニット数）」の絞り込みである。2 値分類タスクにおいては、一方のクラスの事後確率 p が決定されれば、確率の公理より他方のクラスの事後確率は $1 - p$ として一意に定まる。予測すべき値は 1 つであるため、複数の出力ユニットを用意することはパラメータの無駄な冗長性を生む。

このネットワーク $y(\mathbf{x}; \mathbf{w})$ は、以下のように表される。

$$\begin{aligned} u &= \mathbf{w}^\top \mathbf{x} + b \\ y(\mathbf{x}; \mathbf{w}) &= f(u) \\ y(\mathbf{x}; \mathbf{w}) &\in (0, 1), \quad u \in \mathbb{R}, \quad \mathbf{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_I \end{pmatrix} \in \mathbb{R}^I, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_I \end{pmatrix} \in \mathbb{R}^I, \quad b \in \mathbb{R} \end{aligned}$$

⁸C. M. ビショップ：パターン認識と機械学習 下 ベイズ理論による統計的予測，p.76，シュプリンガー・ジャパン株式会社，東京（2008）。

⁹「隠れ変数」や「非観測変数」とも呼ばれる。

¹⁰C. M. ビショップ：パターン認識と機械学習 上 ベイズ理論による統計的予測，p.21，シュプリンガー・ジャパン株式会社，東京（2008）。

¹¹ReLU などの活性化関数は特定の点において微分不可能である。しかし実用上は、劣微分を用いるなどして勾配降下法による学習が問題なく成立する。「大部分において」という表現は、このような実態を許容するものである。

- $y(\boldsymbol{x}; \boldsymbol{w})$: 入力 $\boldsymbol{x}$ に対するロジスティック回帰モデルの出力（重み $\boldsymbol{w}$ に依存する関数）
- f : 活性化関数
- u : 線形関数の出力値
- $\boldsymbol{w}$: 重みベクトル（パラメータ）
- $\boldsymbol{x}$: 入力
- b : バイアス

まだ活性化関数 f の中身は、定義されていない。式 (1) より、モデルは線形関数の出力 $u \in (-\infty, \infty)$ を、活性化関数 f によって事後確率 $p \in (0, 1)$ へ変換する必要がある。この時、出力値を単に丸め込むのではなく、意味のある変換を行わなければならない。

活性化関数の決定