

# 機械学習

佐々木翔太

## 1 分類

### 1.1 ロジスティック回帰による 2 値分類

#### 1.1.1 目的

ここでは、ロジスティック回帰を構成する各要素の必然性を明らかにする事を目的とする。

#### 1.1.2 問題設定

2 値分類タスク<sup>1</sup>とは、入力  $\mathbf{x}$  をその内容に応じて 2 種類に区別する問題である。クラスラベルは、2 値の変数  $k \in \{0, 1\}$  で表現するものとする。2 値分類タスクの目標は、入力  $\mathbf{x}$  から  $k$  を推定する事である。

この問題を定式化するため、入力  $\mathbf{x}$  を指定した時  $k = 1$  となる事後確率<sup>2</sup>  $p(k = 1|\mathbf{x})$  を考える<sup>3</sup>。  $\mathbf{x}$  が与えられた時、事後確率  $p(k = 1|\mathbf{x})$  を計算し、その値が 0.5 を超えれば  $k = 1$ 、下回れば  $k = 0$  と判断する<sup>4</sup>。

ここでは、入力を  $I$  次元の列ベクトル  $\mathbf{x} \in \mathbb{R}^I$  と定義する。例えば画像の 2 値分類タスクであれば、 $\mathbf{x}$  は画像から抽出された単一の特徴ベクトルを意味する。また、セグメンテーションや物体検出などの 2 値分類タスクであっても、最終的には「特定のピクセルやグリッドにおける特徴ベクトルに対する独立した 2 値分類の反復」に帰着する<sup>5</sup>。 よって、入力データの次元に依らず、2 値分類モデルは「列ベクトル  $\mathbf{x}$  から事後確率  $p \in (0, 1)$  への写像（全射）<sup>6</sup>」として一般化して議論できる。

$$f: \mathbb{R}^I \rightarrow (0, 1), \quad \mathbf{x} \mapsto p$$
$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_I \end{pmatrix} \in \mathbb{R}^I, \quad p \in (0, 1)$$

なお、 $p \in (0, 1)$  であり、 $p \in [0, 1]$  ではない。この理由は、ロジスティックシグモイド関数<sup>7</sup>の議論において後述する。

#### 1.1.3 なぜ予測モデルの出力が「確率」なのか

現実の対象が持つ完全な情報を有限次元の特徴ベクトル  $\mathbf{x}$  に圧縮して観測する以上、観測されていない潜在変数<sup>8,9</sup>が存在する。この情報の欠落により、現実にはクラス  $k = 0$  に属するデータと  $k = 1$  に属するデータが、特徴空間上で全く同じ座標に位置する可能性がある。例えば、ある人物について「身長 170cm」という特徴ベクトル  $\mathbf{x}$  が与えられ、その人物の性別を予測するタスクを考えると、正解ラベルは女性にも男性にもなり得る。

<sup>1</sup>以降は「2 値分類」という言葉の使用を避け、「2 値分類タスク」なのか「2 値分類モデル」なのかを明示する。

<sup>2</sup>C. M. ビショップ：パターン認識と機械学習 上 ベイズ理論による統計的予測, p.16, シュプリンガー・ジャパン株式会社, 東京 (2008)。

<sup>3</sup> $p$  は、入力  $\mathbf{x}$  に対してダイナミックに変化するため、条件付き確率である。ここでは事後確率と呼ぶ。

<sup>4</sup>岡谷貴之：深層学習 改訂第 2 版, p.19, 講談社, 東京 (2024)。

<sup>5</sup>要出典

<sup>6</sup>数学の景色：関数とは何か、写像とは何かを図解～定義と表記法と具体例～, <https://mathlandscape.com/function/#toc8>, (2026 年 4 月 30 日参照)。

<sup>7</sup>「ロジスティック関数」とも呼ばれる。

<sup>8</sup>C. M. ビショップ：パターン認識と機械学習 下 ベイズ理論による統計的予測, p.76, シュプリンガー・ジャパン株式会社, 東京 (2008)。

<sup>9</sup>「隠れ変数」や「非観測変数」とも呼ばれる。

同一の入力  $\mathbf{x}$  に対して、正解ラベルが複数存在し得る以上、予測モデルは絶対的な  $\{0, 1\}$  の判断ではなく、不確実性を表す値を出力する必要がある。

そして、不確実性について合理的で一貫した推論を行う唯一の枠組みが確率論であるため、不確実性を表現するために確率を使う<sup>10</sup>。

#### 1.1.4 なぜ予測モデルは「微分可能な連続関数」である必要があるのか

前項により、モデルの出力値は確率となったが、これだけではモデルの学習は保証されない。ロジスティック回帰モデルのパラメータ最適化に勾配降下法を採用する事を仮定すると、入力  $\mathbf{x}$  から確率  $p$  への写像（モデル）は、定義域の大部分において微分可能な連続関数でなければならない。たとえ出力値が確率であっても、入力の変化に対して確率が階段状に変化する離散的な関数であった場合、その微分値は至る所で 0 となり、勾配が消失してしまう。よって学習を成立させるためには、モデルは単に確率を出力するだけでなく、入力に対して滑らかに連続変化する微分可能な関数として設計されなければならない。

#### 1.1.5 モデル出力の設計と「ロジスティックシグモイド関数」の必然性

これまでの説明により、2 値分類モデルは少なくとも以下の条件を満たさなければならない事が示された。

- 予測モデルの出力値は、不確実性を表現する「確率」である。
- 予測モデルは、勾配の消失を防ぎ最適化を可能にするため、「微分可能な連続関数」である。

事後確率  $p(k = 1|\mathbf{x})$  をモデル化するために、ニューラルネットワークを使用する。

---

<sup>10</sup>C. M. ビショップ：パターン認識と機械学習 上 バイズ理論による統計的予測，p.21，シュプリンガー・ジャパン株式会社，東京（2008）。